

Calcul Bayésien

Anne Philippe

Laboratoire de Mathématiques Jean Leray
Université de Nantes

24 mai 2010

Deux grandes étapes

① Simuler des nombres aléatoires suivant une loi donnée

② Exploiter ces données :

~~> Méthode de Monte Carlo [MC]

1 Introduction

2 Approximation

3 Simulation de variables aléatoires

4 Méthodes de Monte Carlo par chaînes de Markov

On a besoin de la simulation de variables aléatoires

- Crash de voitures
- Prévisions probabilistes
- Fiabilité : simulation d'événements rares
- Bootstrap
- Problèmes bayésiens ou non d'estimation
le calcul des estimateurs, les régions de confiance etc
- ~~> développement de méthodes numériques basées sur le hasard :
Méthodes de Monte Carlo

Problèmes spécifiques à l'approche bayésienne

- Calcul de la loi a posteriori $\pi(\theta|x) \propto \pi(\theta)f(x|\theta)$
- Calcul des quantités a posteriori

$$\delta^\pi(x) = \int_{\Theta} h(\theta) \pi(\theta|x)d\theta = \frac{\int_{\Theta} h(\theta) \pi(\theta)f(x|\theta)d\theta}{\int_{\Theta} \pi(\theta)f(x|\theta)d\theta}$$

- etc

Techniques usuelles

~~ méthodes d'analyse numérique

- méthode des trapèzes, quadrature par polynômes etc

Commentaires :

- ① Difficulté à juger de la valeur de l'approximation.
- ② au delà de la dimension 3, mauvaises performances.

Alternative :

Méthode de Monte Carlo

1 Introduction

2 Approximation

3 Simulation de variables aléatoires

4 Méthodes de Monte Carlo par chaînes de Markov

Idée centrale de Monte Carlo

On exprime l'intégrale que l'on cherche à approcher sous la forme

$$\int_{\mathcal{X}} h(x)f(x) dx = \mathbb{E}(h(X)) \quad X \sim f$$

- f probabilité
- h une fonction intégrable [par rapport à f]

Clé : Tirer profit de la représentation de l'intégrale sous la forme d'une moyenne

Description de la méthode

- Simuler

$$X_1, \dots, X_m \sim f(x)$$

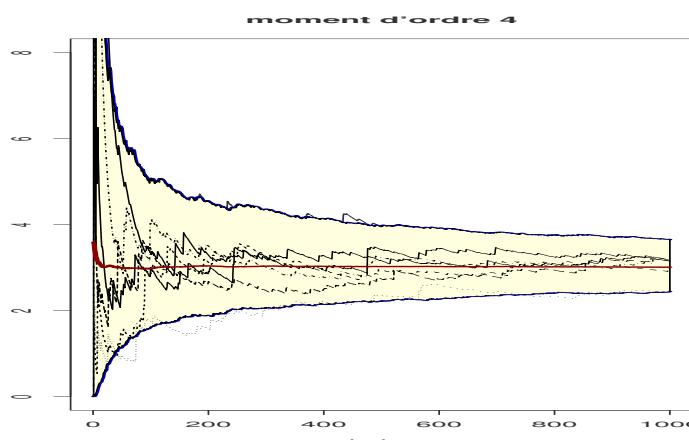
- Utiliser [la loi des grands nombres]

$$I_m = \underbrace{\frac{1}{m} \sum_{i=1}^m h(X_i)}_{\text{Moyenne empirique}} \xrightarrow{m \rightarrow \infty} \int_{\mathcal{X}} h(x)f(x) dx$$

Propriétés : indépendantes de la dimension

- $\mathbb{E}(I_m) = \int_{\mathcal{X}} h(x)f(x) dx$
- $\text{Var}(I_m) = \frac{1}{m} \text{Var}(h(X_1))$

Estimation du moment d'ordre 4 par Monte Carlo

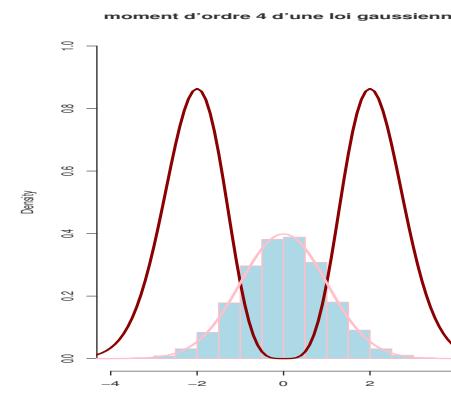


La variance est grande !!

Changement de loi

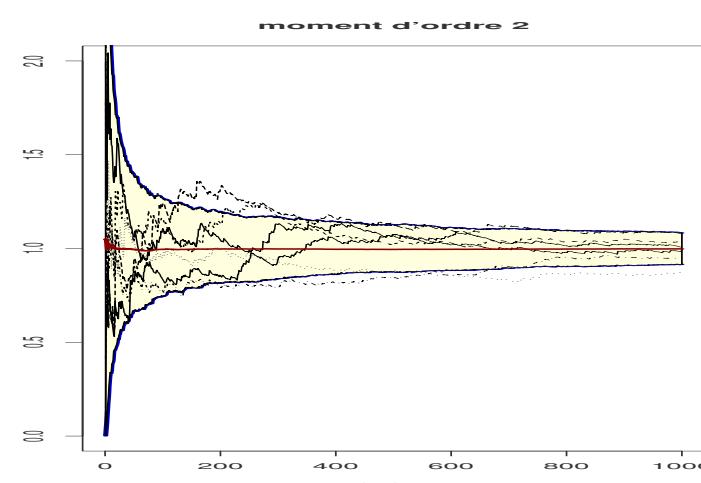
Exemple

On estime le moment d'ordre 4 d'une loi gaussienne standard



Représentation de $f(x)$ et $x^4 f(x)$

En effet, pour le moment d'ordre 2, on obtient



Simulation par changement de loi

On utilise la représentation

$$\int_{\mathcal{X}} h(x)f(x) dx = \int_{\mathcal{X}} \frac{h(x)f(x)}{g(x)} g(x) dx$$

g est une probabilité

- ➊ Générer $y_1, \dots, y_m \sim g$.
- ➋ Utiliser l'approximation

$$\frac{1}{m} \sum_{i=1}^m h(y_i) \frac{f(y_i)}{g(y_i)},$$

Estimation d'évènements rares

Exemple

Queue de la distribution d'une va gaussienne

$$P(X > x) = \mathbb{E}(\mathbb{I}_{[x, \infty]}(X))$$

On va choisir une loi qui donne plus de poids que la gaussienne aux queues de la distribution
par exemple la loi de Cauchy.

Comment choisir la densité g

Choix optimal

$$g^*(x) = |h(x)|f(x) \frac{1}{\int_{\mathcal{X}} |h(x)|f(x) dx}$$

Ce résultat est purement théorique car l'estimateur dépend de f/g^* et donc de l'intégrale $\int_{\mathcal{X}} |h(x)|f(x) dx$ qui est inconnue !!

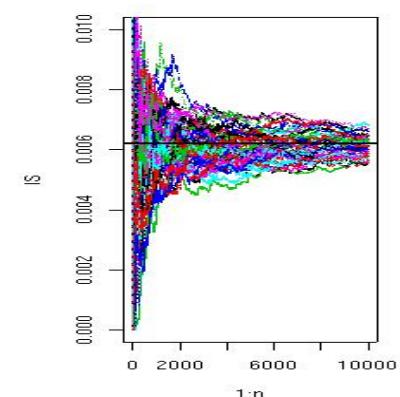
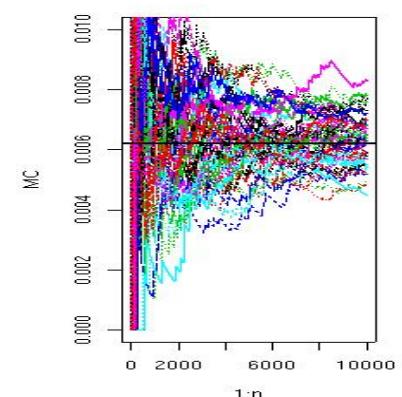
En pratique ...

On prend g qui ressemble à la fonction $|h|f$ et $|h|f/g$ bornée

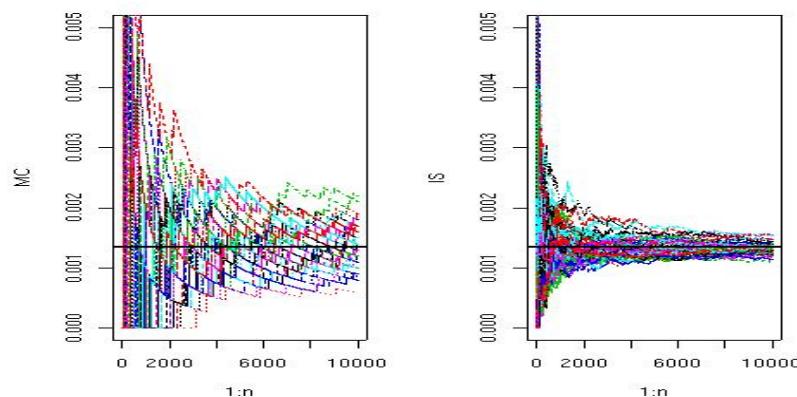
[finitude de la variance]

Résultats pour $x = 2.5$

- A gauche : échantillon simulé suivant la loi gaussienne
- A droite : échantillon simulé suivant la loi de Cauchy



Résultats pour $x = 3$



Existence

On peut toujours simuler un échantillon suivant une loi donnée à partir

- d'un échantillon iid suivant la loi uniforme sur $[0, 1]$
- F^- le pseudo inverse de la fonction de répartition

Exemple : pour la loi exponentielle on a $F^-(U) = -\log(1 - U)$

En pratique : souvent F^- n'est pas connue explicitement

1 Introduction

2 Approximation

3 Simulation de variables aléatoires

4 Méthodes de Monte Carlo par chaînes de Markov

Théorème fondamental

Théorème

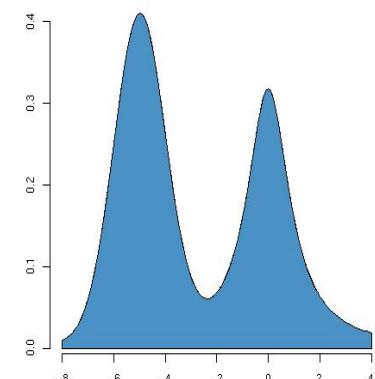
Soit h une fonction positive.

Si

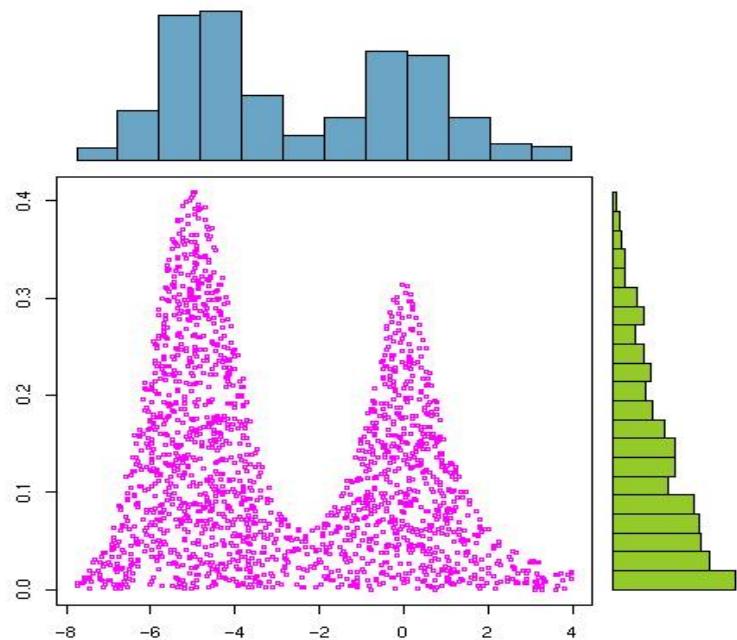
$$(X, Y) \sim \text{Uniforme}\{(x, y) : 0 \leq y \leq h(x)\}$$

alors la loi marginale de X admet pour densité

$$\frac{h}{\int h(t) dt}$$



Le résultat



A. Flippé (Univ. Nantes)

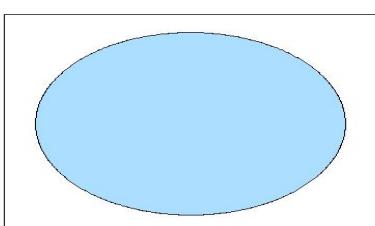
Calcul Bayésien

Simulation de variables aléatoires

24 mai 2010

21 / 57

Cas particulier de la loi uniforme

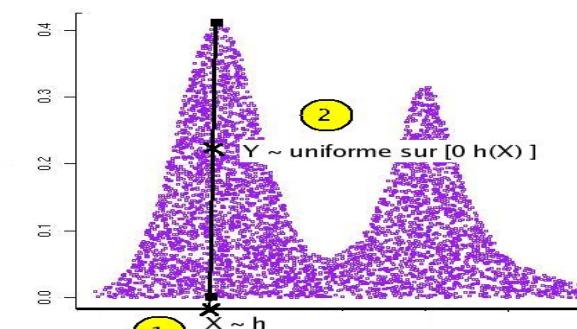
Pour simuler x suivant la loi uniforme sur A (région en bleue)

1. On simule y suivant la loi uniforme sur $[0, 1]^2$
2. Si $y \in A$ alors on pose $x = y$ sinon on recommence

Algorithme

Pour simuler x suivant la loi uniforme sur

$$\{(x, y) : 0 \leq y \leq h(x)\}$$



1. On simule x suivant la loi de densité $\frac{h}{\int h(t) dt}$
2. On simule y suivant la loi uniforme sur $[0, h(x)]$

A. Flippé (Univ. Nantes)

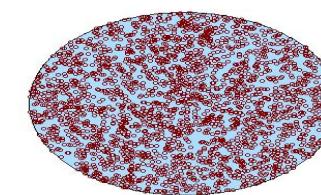
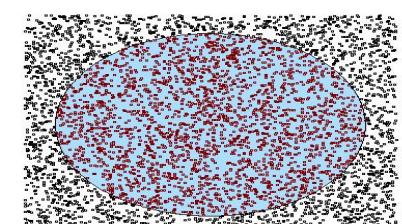
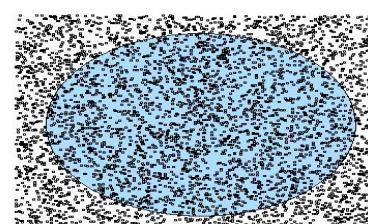
Calcul Bayésien

Simulation de variables aléatoires

24 mai 2010

22 / 57

Résultats

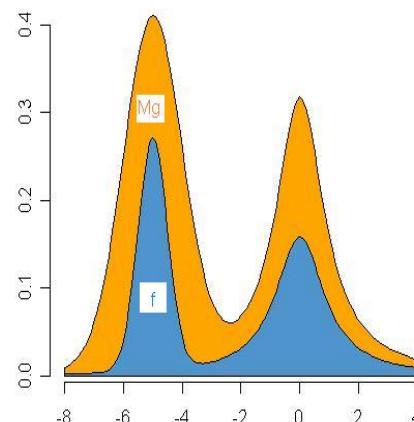


Algorithme d'acceptation rejet

On veut simuler $x \sim f$.

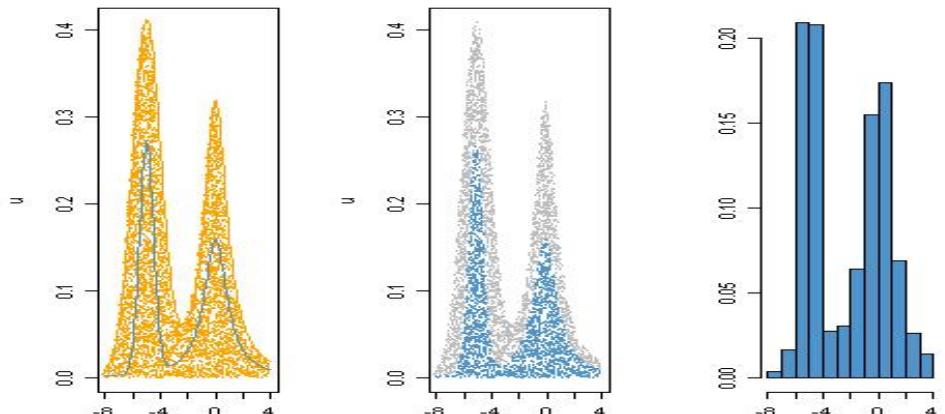
Ingrediént : g une probabilité telle que

- f/g est bornée par M
- on peut facilement simuler suivant g



L'algorithme

1. Générer $z \sim g(z)$ et $u \sim \text{Uniforme}[0, Mg(z)]$.
2. Si $u \leq f(z)$, on prend $x = z$;
Sinon on répète 1.



Comment choisir g

- Le nombre **moyen** de variables simulées suivant g pour obtenir **une** variable suivant f est égal M
 $\rightsquigarrow M$ proche de 1 : l'algorithme est efficace
- En pratique on prend g qui ressemble à f
- Il n'est pas nécessaire de connaître la constante de normalisation de f
 Intérêt en bayésien il n'est pas utile de connaître la loi marginale des observations

1 Introduction

2 Approximation

3 Simulation de variables aléatoires

4 Méthodes de Monte Carlo par chaînes de Markov

Chaînes de Markov -

Idée : Il est souvent plus facile de simuler

une chaîne de Markov de loi invariante f
que
des variables indépendantes de loi f

Définition

Une chaîne de Markov est une suite de variables (X_t) telle que pour tout n la loi conditionnelle de X_{n+1} sachant (X_n, \dots, X_0) et la loi conditionnelle de X_{n+1} sachant X_n coïncident.

Exemple

Soit (u_t) une suite de variables aléatoires iid

- on pose $X_0 \sim \pi_0$ et $X_t = \rho X_{t-1} + u_t$
 (X_t) est une chaîne de Markov.
- Plus généralement : on peut prendre $X_t = g(X_{t-1}, u_t)$ où g est une application mesurable

Construction

Une chaîne de Markov est donc définie par

- la loi de X_0
- la loi de X_t sachant X_{t-1} (transition de la chaîne)
 - l'espace d'état E est fini : la transition est une matrice P
 $P(i, j) = P(X_1 = j | X_0 = i)$
 - l'espace d'état E est continu : la transition est une famille de densités $\{K(x, \cdot), x \in E\}$ où $K(X_n, \cdot)$ est la densité de la loi conditionnelle de X_{n+1} sachant X_n

$$P(X_{n+1} \in A | X_n) = \int_A K(X_n, y) dy$$

- dans le cas général la transition est $P(x, A) = P(X_1 \in A | X_0 = x)$
- $P^n(x, A)$ probabilité que $x_n \in A$ sachant que $x_0 = 0$

Propriétés des chaînes de Markov

chaîne irréductible : toute région d'intérêt de l'espace d'états peut être visitée.

- *transient* : nombre moyen de passages est fini
- *recurrent* : garantie de retour

Loi invariante : On dit que la chaîne admet une loi invariante s'il existe f telle que

$$\text{si } x_n \sim f \text{ alors } x_{n+1} \sim f$$

Les chaînes construites par les algorithmes MCMC admettent une loi invariante et elle est unique.

Notions de convergence

Étant donné une loi de probabilité de densité f

On cherche des transitions telles que

- ➊ la loi invariante est unique et de densité f ,
- ➋ la loi de x_n est "proche" de la loi invariante f lorsque n assez grand et $x_0 \sim P_0 \neq f$

$$\left\| \int P^n(x,) dP_0(x) - f \right\|_{TV} \rightarrow 0$$

- ➌ Théorème ergodique

$$\frac{1}{T} \sum_{t=1}^T h(x^{(t)}) \xrightarrow{T \rightarrow \infty} \int h(x) f(x) dx$$

propriétés

Lorsque $\text{supp } q(\cdot|x) \supset \text{supp } f$,
 $(x^{(t)})$ est

- ➊ irréductible
- ➋ ergodique,
- ➌ de distribution invariante f .

Algorithme de Métropolis–Hasting

On veut simuler $x \sim f$.

Ingrédient : q une probabilité $q(\cdot|x^{(t)})$ telle que

$$\text{supp } q(\cdot|x) \supset \text{supp } f,$$

L'algorithme : partant de $x^{(t)}$, la transition de la chaîne est

$$x^{(t+1)} = \begin{cases} \xi \sim q(\xi|x^{(t)}) & \text{avec probabilité } \rho, \\ x^{(t)} & \text{sinon,} \end{cases}$$

où

$$\rho = \min \left\{ 1, \frac{f(\xi)q(x^{(t)}|\xi)}{f(x^{(t)})q(\xi|x^{(t)})} \right\}$$

Exemples de lois instrumentales

- ➊ Lois indépendantes :

$$q(\xi|x) = g(\xi)$$

On "généralise" l'algorithme d'acceptation-rejet dans le sens où il y a moins de contraintes sur la loi instrumentale g

- ➋ Lois symétriques :

$$q(\xi|x^{(t)}) = h(|\xi - x^{(t)}|)$$

Le taux d'acceptation ne dépend pas de la loi q ,

$$\rho = \min\left(\frac{f(\xi)}{f(\theta^{(t)})}, 1\right).$$

les marches aléatoires

Un exemple de lois symétriques : partant de $x^{(t)}$, la transition s'écrit

$$\xi = x^{(t)} + \varepsilon$$

où $\varepsilon^{(t)}$ est une suite de variables aléatoires iid et indépendantes de (X_0, \dots, X_t)

la loi de ε est symétrique par rapport à zéro,
par exemple

- les lois gaussiennes $\mathcal{N}(0, \sigma^2)$,
- les lois uniformes sur $[-a, a]$,
- etc...

Exemple original de Hastings (1970)

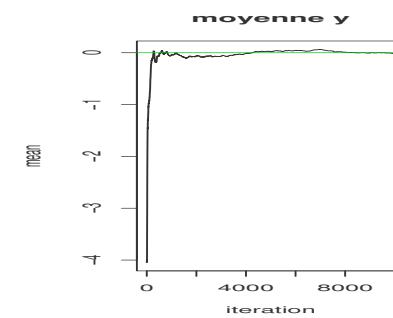
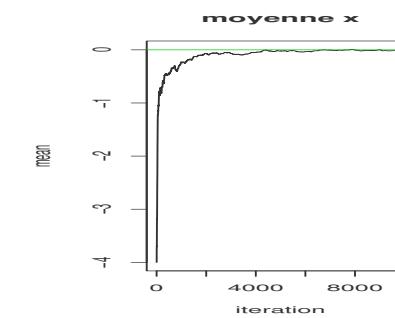
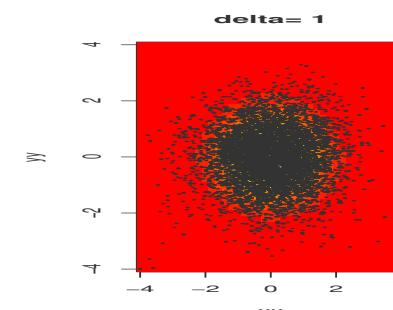
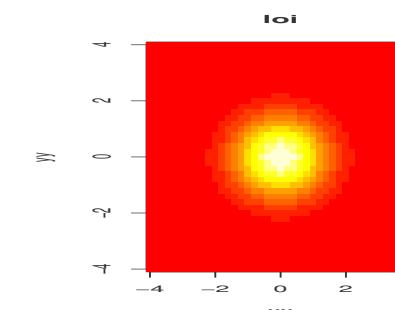
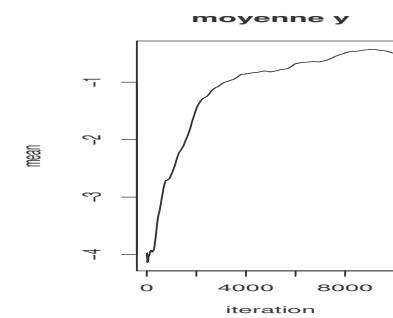
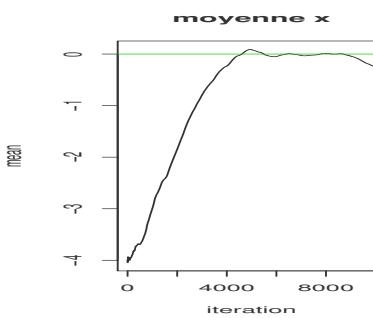
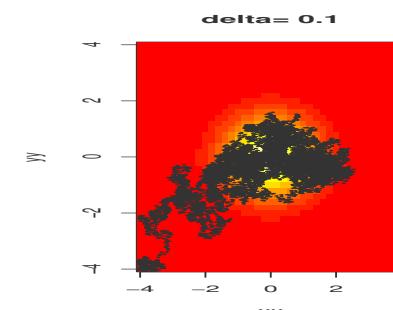
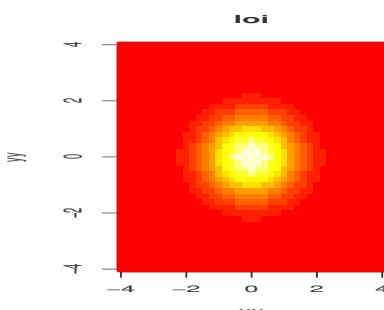
On simule un vecteur gaussien dans le plan $\mathcal{N}\left(0, \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}\right)$

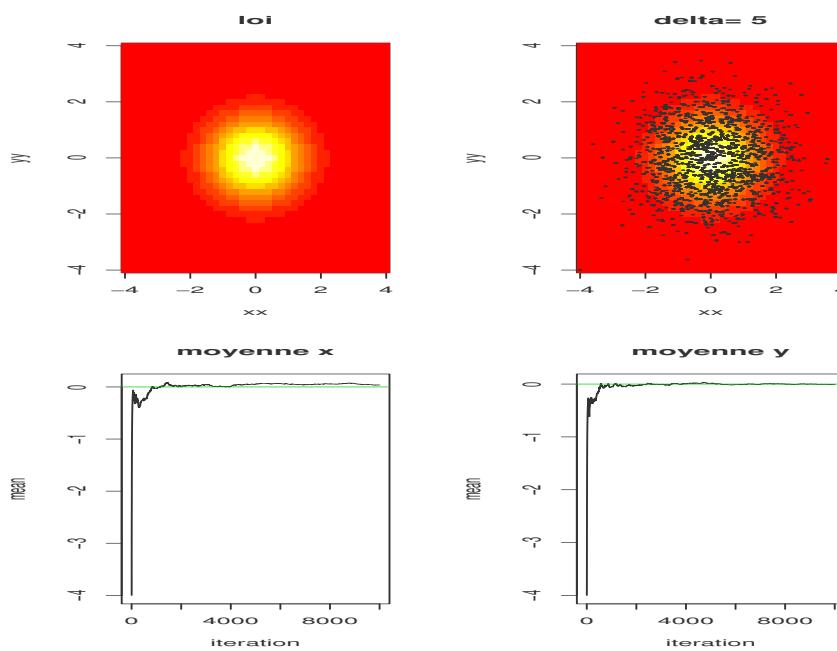
La loi instrumentale est symétrique, on prend une marche aléatoire construite à partir de la loi uniforme $\mathcal{U}([-a, a])^2$,

$$\xi = x^{(t)} + \alpha \varepsilon_t, \quad \varepsilon_t \sim \mathcal{U}_{[-1,1]^2}$$

On a

$$\rho = \min(\exp\{(x^{(t)2} - \xi^2)/2\}, 1)$$





L'algorithme

On utilise un algorithme d'Hasting Métropolis dont la loi instrumentale est une marche aléatoire gaussienne

Partant de x_t , la valeur proposée ξ est distribuée suivant

$$\xi \sim \mathcal{N} \left(x_t, \begin{pmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{pmatrix} \right)$$

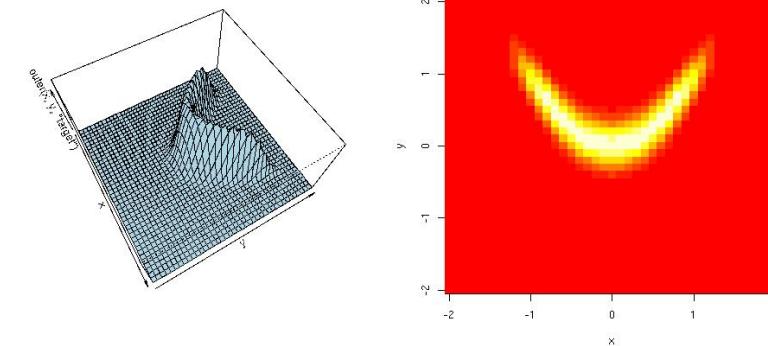
c'est à dire

$$\xi = x_t + \sigma \varepsilon_t \quad \varepsilon_t \sim \mathcal{N} \left(0, \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right)$$

Un second exemple

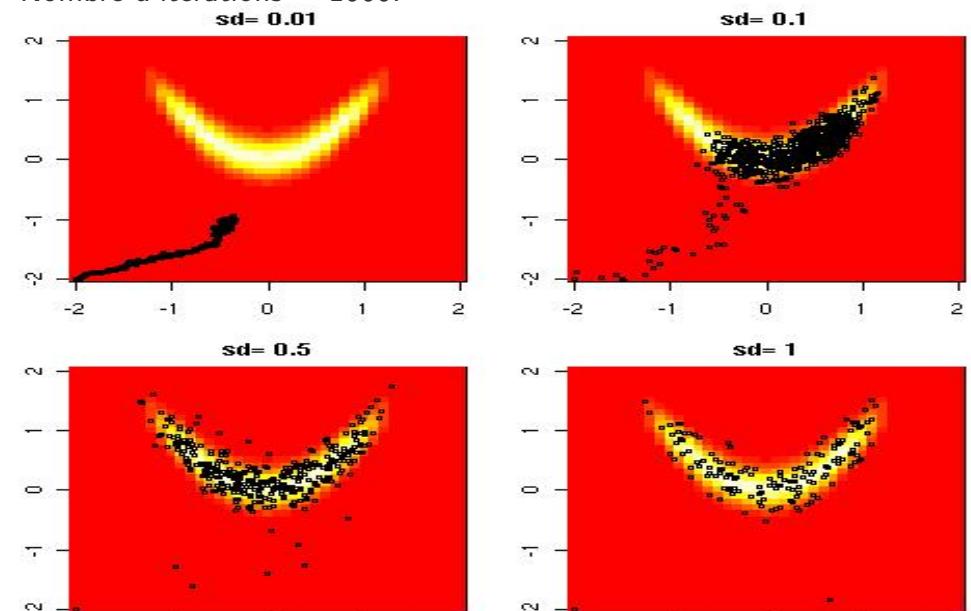
On simule un échantillon suivant une loi de densité dans le plan.

$$f(x, y) \propto \exp\{-10(x^2 - y)^2 - (y - 1/4)^4\}$$



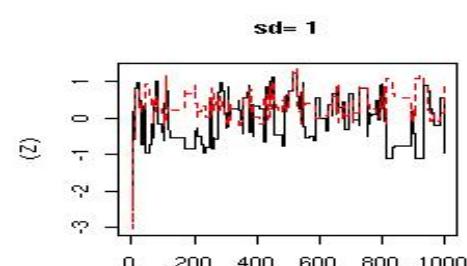
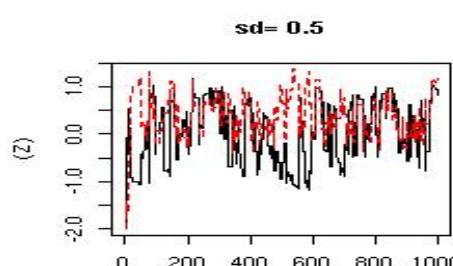
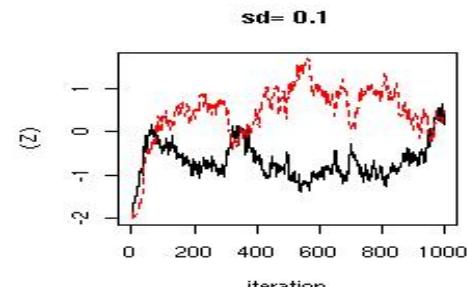
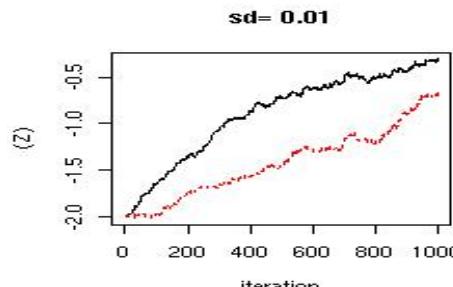
sites visités par la chaîne

Nombre d'itérations = 1000.



Trajectoires des deux coordonnées

Nombre d'itérations = 1000.



L'algorithme : la transition de la chaîne est

$$1. \quad x_1^{(t+1)} \sim f_1(x|x_2^{(t)}, \dots, x_m^{(t)})$$

...

$$i. \quad x_i^{(t+1)} \sim f_i(x|x_1^{(t+1)}, \dots, x_{i-1}^{(t+1)}, x_i^{(t)}, x_m^{(t)})$$

...

$$m. \quad x_m^{(t+1)} \sim f_m(x|x_1^{(t+1)}, \dots, x_{m-1}^{(t+1)})$$

Algorithme de Gibbs

On veut simuler $x \sim f$ en dimension $p > 1$!!!

Outil central : une décomposition de $x \in \mathbb{R}^p$ en m blocs

$$x = (x_1, \dots, x_m)$$

telle que

les lois conditionnelles

$$f_j(x_j|x_\ell, \ell \neq j), \quad j = 1, \dots, m$$

sont simulables.

Exemple

La loi à simuler admet pour densité

$$f(x, y) \propto e^{-x-y-xy} \mathbb{I}_{R^+ \times \mathbb{R}^+}(x, y)$$

On calcule les deux lois conditionnelles

- la loi de X sachant Y est la loi exponentielle de paramètre $Y + 1$
- la loi de Y sachant X est la loi exponentielle de paramètre $X + 1$

L'algorithme :

Initialisation $Y_0 \sim \mathcal{E}(1)$

Itération 1. $X_1 \sim \mathcal{E}(1 + Y_0)$ et $Y_1 \sim \mathcal{E}(1 + X_1)$

⋮

Intération i. $X_i \sim \mathcal{E}(1 + Y_{i-1})$ et $Y_i \sim \mathcal{E}(1 + X_i)$

Propriétés

Si $f(x) > 0$ sur E alors $(x^{(t)})$ est une chaîne de Markov

- ① ergodique
- ② de loi invariante $f(x)$
- ③ Harris récurrentes [*lorsque les densités sont continues*].

Augmentation de la dimension

Lorsque

f est une probabilité sur \mathbb{R}

ou/et les lois conditionnelles sont difficiles à simuler

on peut augmenter la dimension pour simplifier la simulation

$$f(x) = \int g(x, y) dy$$

On simule alors $(x^{(t)}, y^{(t)})$ une chaîne de Markov de loi stationnaire g via un algorithme de Gibbs.

La suite $(x^{(t)})$ est aussi une chaîne de Markov de loi stationnaire f .

un second intérêt à l'augmentation de la dimension

On peut améliorer l'approximation de l'intégrale $\mathbb{E}(h(X))$ avec $X \sim f$ en prenant

$$\mathbb{E}[h(X)] \simeq \frac{1}{K} \sum_{k=1}^K \mathbb{E}[h(X)|y^{(k)}]$$

En effet

$$\mathbb{E}(h(X)) = \mathbb{E}(\underbrace{\mathbb{E}(h(X)|Y)}_{\text{fonction de } Y})$$

Il y a réduction de la variance

[théorème de Rao-Blackwell]

Exemple : loi normale tronquée

$$f(x) \propto e^{-\frac{1}{2\sigma^2}(x-\mu)^2} \mathbb{I}_{[a, \infty]}(x) = \int g(x, y) dy$$

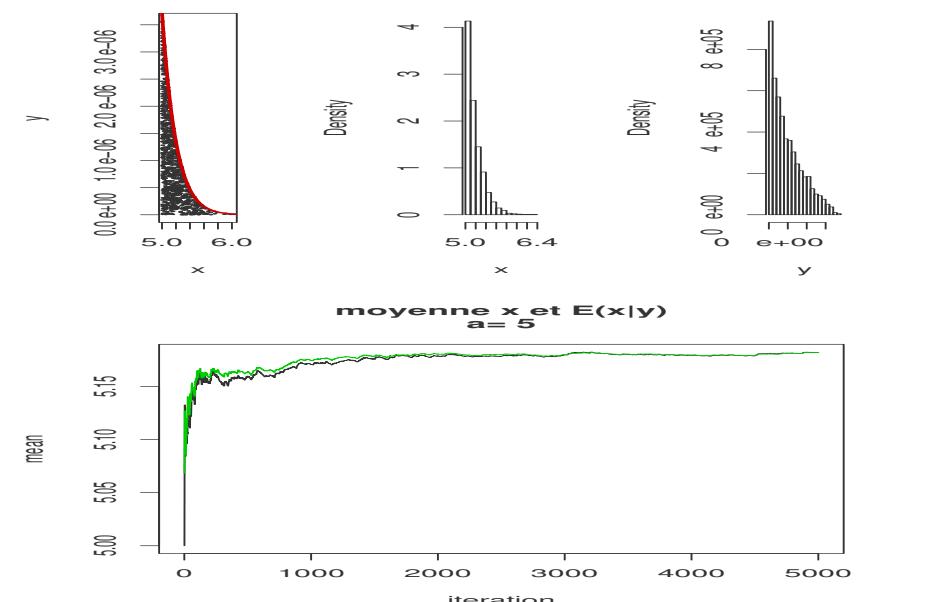
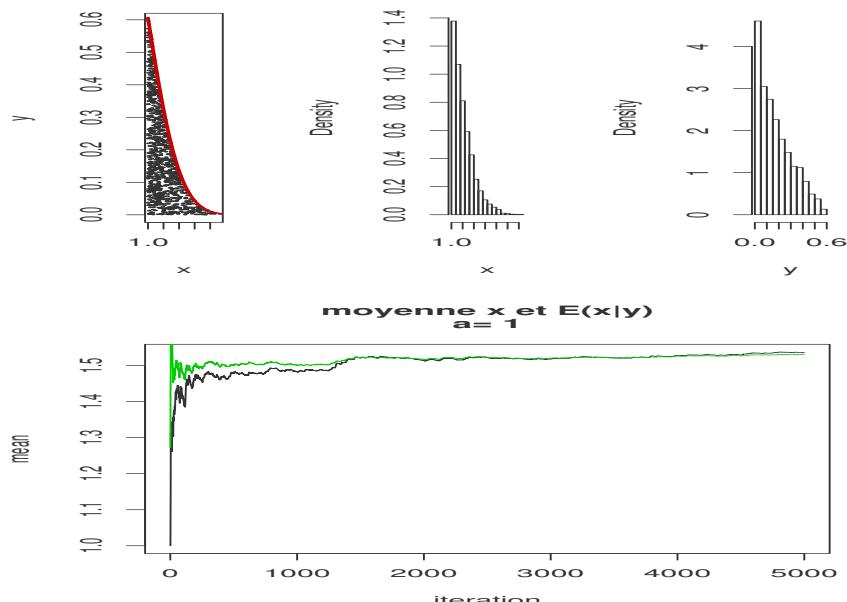
où

$$g(x, y) \propto \mathbb{I}_{[a, \infty]}(x) \mathbb{I}_{[0, e^{-\frac{1}{2\sigma^2}(x-\mu)^2}]}(y)$$

Les lois conditionnelles sont des lois uniformes

$$g(x|y) \sim \mathcal{U}(a, \mu + \sqrt{-2\sigma^2 \log(y)})$$

$$g(y|x) \sim \mathcal{U}(0, e^{-\frac{1}{2\sigma^2}(x-\mu)^2})$$



Application aux mélanges de lois exponentielles

$$x \sim p\mathcal{E}(\ell_1) + (1-p)\mathcal{E}(\ell_2)$$

On cherche à approcher la loi a posteriori des paramètres

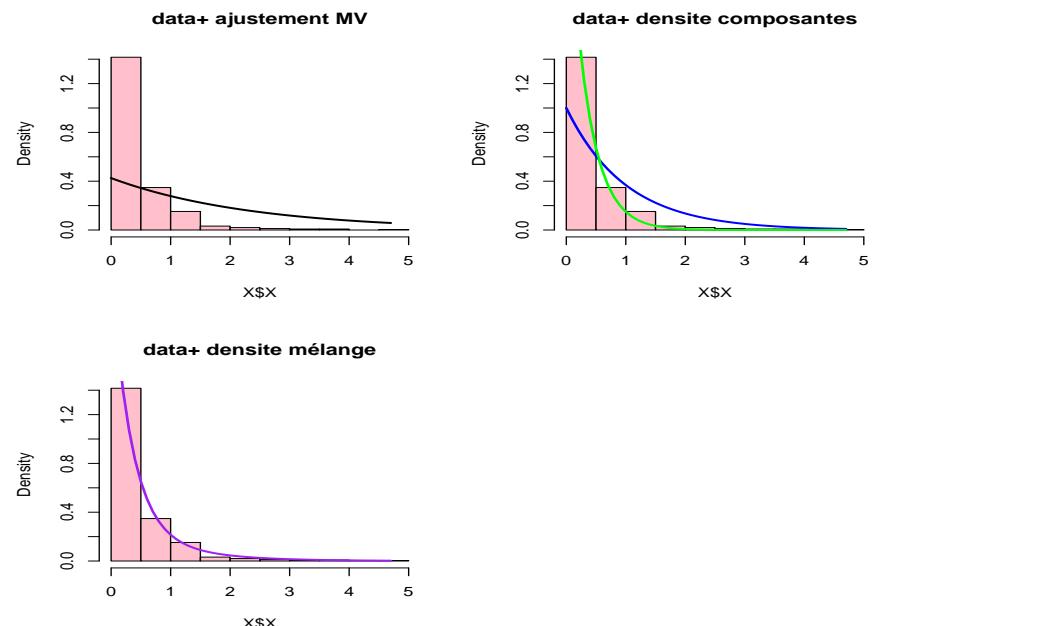
$$p, \ell_1, \ell_2 = \tau\ell_1, z_i, i = 1 \dots n$$

Les lois conditionnelles sont facilement simulables

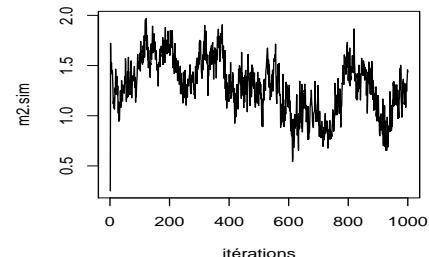
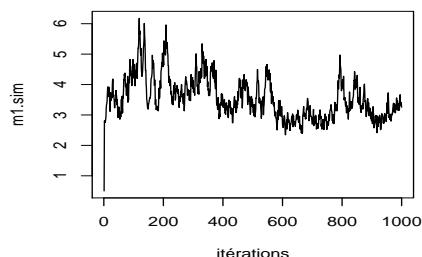
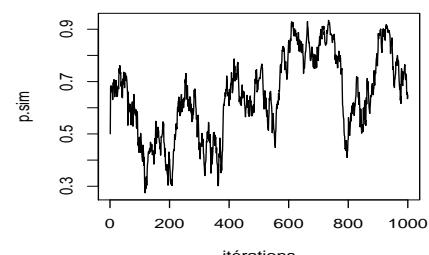
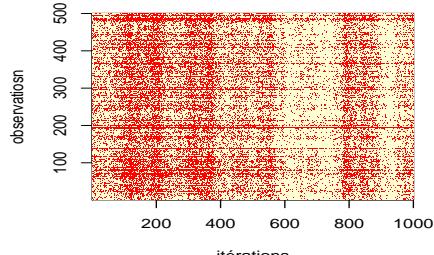
$$z_i | x_1, \dots, x_n, p, \theta_1, \theta_2 \sim \text{bernoulli} \left(\frac{pf_1(x_i)}{pf_1(x_i) + (1-p)f_2(x_i)} \right)$$

$$p | x_1, \dots, x_n, z_1, \dots, z_n, \ell_1, \ell_2 \sim \text{beta}(1 + \sum_i z_i, 1 + n - \sum_i z_i)$$

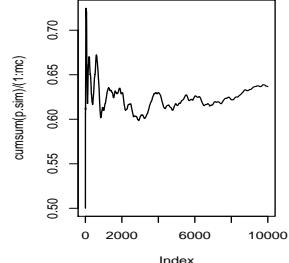
etc



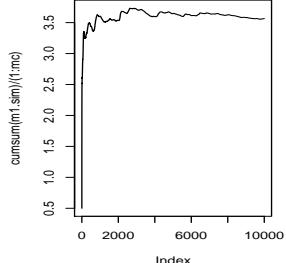
chaines simulées par un algo de Gibbs



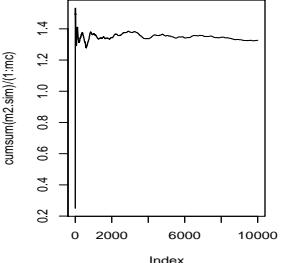
est. de p



est. de m1



est. de m2



Contrôle de la convergence des algorithmes

Il est plus simple de simuler une chaîne de Markov de loi stationnaire f que des variables aléatoires suivant f

MAIS

Il faut contrôler

- la convergence vers la loi stationnaire de la chaîne de Markov
- la qualité de l'approximation de $\int h(x)f(x) dx$ par la moyenne empirique $T^{-1} \sum_{t=1}^T h(x^{(t)})$

Deux critères d'arrêt :

- T_1 le temps de chauffe : on élimine les premières valeurs x_1, \dots, x_{T_1}
- T_2 le temps de simulation

$$T_2^{-1} \sum_{t=T_1+1}^{T_1+T_2} h(x^{(t)}) \approx \int h(x)f(x) dx$$

Méthodes graphiques

- Tracé de la série brute,
- Comparaison de différentes estimations pour une même quantité [Moyenne, Rao-Blackwell]
- comparaison des estimations d'une même quantité effectuées sur des chaînes indépendantes

Méthode basée sur plusieurs chaînes Gelman & Rubin

On suppose que l'on a simulé M chaînes de Markov indépendantes

$$\bar{x}_m = \frac{1}{T} \sum_{t=1}^T x_m^{(t)}, \quad \bar{x} = \frac{1}{M} \sum_{m=1}^M \bar{x}_m,$$

Estimateurs des variances *inter* et *intra*

$$B_T = \frac{1}{M} \sum_{m=1}^M (\bar{x}_m - \bar{x})^2,$$

$$W_T = \frac{1}{M} \sum_{m=1}^M s_m^2 = \frac{1}{M} \sum_{m=1}^M \frac{1}{T} \sum_{t=1}^T (x_m^{(t)} - \bar{x}_m)^2$$

Critère

Pour T assez grand

$$W_T \sim \frac{T-1}{T} W_T + B_T$$